DĚLAT DOBRÝ SOFTWARE NÁS BAVÍ

PROFINIT

Spark

Jan Hučín

15. listopadu 2017

Agenda

- 1. What is it (for)
- 2. How to learn it
- 3. How to work with it
- 4. How it works
 - logical / technical level
 - transformations, actions, caching
 - examples
 - architecture, sources

Later:

- Spark SQL
- Spark streaming




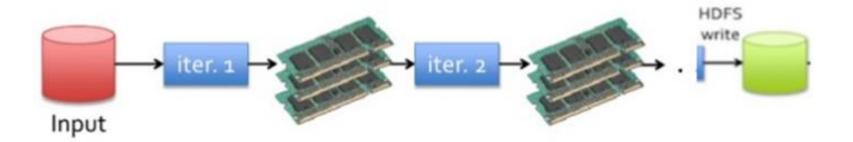
What is Spark

(For) what is Spark

- framework for distributed computations
- improved map-reduce by 2 orders
 - in-memory processing less I/O operations, good for iterations and data analysis
 - operation optimisation before processing
 - enhanced by SQL-like commands
- API for Scala, Java, Python, R
- on Hadoop (using HDFS, YARN) or standalone
- written in Scala
- processing in JVM
- > the most active (2017) opensource Big Data project

Spark vs. map-reduce





Suitable tasks

- big enough, but not extreme
- able to be parallelized
- iterative
- not resolvable by traditional technologies
- E.g.
- 1. sophisticated client features (risk score)
- complicated SQL tasks for DWH
- 3. compute once (night), use many (day)
- 4. graph/network analysis
- 5. text-mining

Not suitable tasks

- > too small
- with extreme memory demands
- custom-tailored for other technologies (SQL, Java)
- unable to be parallelized
- strictly real-time

E.g.

- 1. small data modelling
- 2. median computation, random skipping in the file
- 3. JOIN of really big tables

How to learn it


- http://spark.apache.org
- basics of Python | Scala | Java | R
- self-practice
- advice of experienced, StackOverflow etc.

How to work with it

- interactively
 - command line (shell for Python and Scala)
 - Zeppelin/Jupyter notebook
- batch / application
 - compiled .jar file
 - Python script

How Spark works

Logical level (high)




- series of transformations finished by action
- > transformation are **planned** and **optimized**, but **not made**
- > lazy evaluation: action starts all process

What is RDD?

- resilient distributed dataset
- item collections (line of a text file, files in a direktory, data matrix, etc.)
- must be divisible to parts Spark does the division itself

Technical level (mid)



- creates JVM on nodes (=executors)
- > application → jobs; job → tasks
- > task (and data) distribution to nodes
- process control
- more later Spark architecture

Spark RDD – transformations

RDD1 ⇒ RDD2, item by item ("row by row")

- map (item ⇒ transforming function ⇒ new item)
- → flatMap (item ⇒ transforming function ⇒ 0 až N new items)
- filter, distinct (only items meeting condition / unique items)
- join (joining other RDD by key)
- union, intersection
- groupByKey, reduceByKey (items agregation by key)
- ... and many others

How to get "key"?

- irst member of *tuple* = key
- result of transformation: word ⇒ (word, 1)

"tuple" (Scala, Python)

map a flatMap



Example 1 – word count

- > Task: count frequency of words in document
- > Input: text file divided to lines
- Output: RDD with items (word, frequency)
- Workflow:
 - import text file as RDD
 - lines transformation: line ⇒ words ⇒ tuples (word, 1)
 - grouping items with same key, summing ones = count

How to launch the interactive shell

pyspark (Python) | spark-shell (Scala)

- from Linux shell in console
- Spark on master node (local) or on YARN:
 - pyspark --master local
 - pyspark --master yarn
- > creates important objects: sc (SparkContext), sqlContext
- many parameters later
- > closed by exit()

Example 1 – word count

- > Task: count frequency of words in document
- > Input: text file divided to lines
- Workflow:
- import text file as RDD
 lines = sc.textFile("/user/pascepet/bible.txt")
- > lines transformation: line ⇒ words
 words = lines.flatMap(lambda line: line.split(" "))
- > lines transformation: words ⇒ tuples (word, 1)
 pairs = words.map(lambda word: (word, 1))
- grouping items with same key, summing ones = count
 counts = pairs.reduceByKey(lambda a, b: a + b)

```
to be or not to be
```

```
to
be
or
not
to
be
```

```
(to, 1)
(be, 1)
(or, 1)
(not, 1)
(to, 1)
(be, 1)
```

```
(to, 2)
(be, 2)
(or, 1)
(not, 1)
```

Why does it not count anything?

Because we have done no action so far.

Spark RDD – actions


- > count
- > take (gets first *n* RDD items)
- collect (gets all items in RDD)
- > reduce (aggregation of all RDD items with function provided)
- saveAsTextFile
- ... and others

- Action starts all chain from the beginning!
 - After run, all results are "forgotten".
 - If we don't want this, we have to cache some RDD.

Caching

- Caching: RDD is not forgotten but saved into memory / on disk.
- Caching methods:
 - cache (try to save in memory)
 - persist (more general can control serialization, disk/memory)
 - unpersist (release RDD from memory/disk)
- Caching types:
 - MEMORY_ONLY
 - MEMORY_AND_DISK
 - MEMORY_ONLY_SER
 - MEMORY_AND_DISK_SER
- > SER = serialization less memory, high computation demands
 - Useful only for Java and Scala; Python makes serialization always
- Caching is not an action!

Spark program as a graph



Příklad 2 – podobnost obrázků

- Úkol: spočítat podobnosti mezi dvojicemi obrázků
- Vstup: čb soubory BMP (4×4, 256 barev) prvky RDD
- Postup:
 - parsing: binární BMP ⇒ posloupnost 16 čísel 0/1
 - vytvoření dvojic obrázků
 - výpočet podobnosti dvojic obrázků
- Výsledek transformace:RDD s prvky (soubor1, soubor2, podobnost)
- Akce na konci např. uložení do textového souboru

Příklad 2 – podobnost obrázků

Úkol: spočítat podobnosti mezi dvojicemi obrázků

Vstup: čb soubory BMP (4×4, 256 barev) – prvky RDD files = sc.binaryFiles("/user/pascepet/pismena/*.bmp")
Postup:


- parsing: binární BMP ⇒ posloupnost 16 čísel 0/1
 filesParsed = files.map(parseBMP)
- vytvoření dvojic obrázků
 filesPairs = filesParsed.cartesian(filesParsed) \
 .filter(lambda f: f[0][0]<f[1][0])</pre>
- výpočet podobnosti dvojic obrázků
 simil = filesPairs.map(similPair)



```
(N, 1001101111011001)
(J, 0110100100010001)
(L, 1111100010001000)
```

```
(N, 1001...), (J, 0110...)
(N, 1001...), (L, 1111...)
(J, 0110...), (L, 1111...)
```

Příklad 2 – parsing



(N, 1001101111011001) (J, 0110100100010001) (L, 1111100010001000)

```
def parseBMP(file):
    name = file[0]
    bytes = file[1]
    bytesLast = bytes[-16:]
    bits = []
    for z in bytesLast:
        if z==' \times 00':
             bits.append(1)
        elif z=='\xff':
             bits.append(0)
        else:
             pass
    return (name, bits)
```

Příklad 2 – podobnost

```
((N, 1001101111011001), (J, 0110100100010001))
def similPair(pair):
    file1 = pair[0]
    file2 = pair[1]
    return (file1[0],file2[0],
            similarity(file1[1],file2[1])
def similarity(bits, pattern=[0]*16):
    sum = 0
    for i in range(0, len(bits)):
        sum += (bits[i]==pattern[i])
    return sum*1.0/len(bits)
                    (N, J, 0.5)
```

Other Spark RDD operations

TRANSFORMATIONS

Essential Core & Intermediate Spark Operations

General

Math / Statistical

Set Theory / Relational

Data Structure / I/O

- map
- filter
- flatMap
- mapPartitions
- mapPartitionsWithIndex
- groupBy
- sortBy

- sample
- randomSplit

- union
- intersection
- subtract
- distinct
- cartesian
- zip

- keyBy
- zipWithIndex
- zipWithUniqueID
- zipPartitions
- coalesce
- repartition
- repartitionAndSortWithinPartitions
- pipe

reduce

- collect
- · aggregate
- fold
- first
- take
- forEach
- top
- treeAggregate
- treeReduce
- forEachPartition
- collectAsMap

- count
- takeSample
- max
- min
- sum
- histogram
- mean
- variance
- stdev
- sampleVariance
- countApprox
- countApproxDistinct

takeOrdered

- saveAsTextFile
- saveAsSequenceFile
- saveAsObjectFile
- saveAsHadoopDataset
- saveAsHadoopFile
- saveAsNewAPIHadoopDataset
- saveAsNewAPIHadoopFile

Essential Core & Intermediate PairRDD Operations

General

- flatMapValues
- groupByKey
- reduceByKey
- reduceByKeyLocally
- foldByKey
- aggregateByKey
- sortByKey
- combineByKey

Math / Statistical

• sampleByKey

Set Theory / Relational

- cogroup (=groupWith)
- join
- subtractByKey
- fullOuterJoin
- leftOuterJoin
- rightOuterJoin

Data Structure

• partitionBy

keys

values

- countByKey
- countByValue
- countByValueApprox
- countApproxDistinctByKey
- countApproxDistinctByKey
- countByKeyApprox
- sampleByKeyExact



Spark architecture

Důležité pojmy 1

Application master


proces zodpovědný za vyjednání výpočetních zdrojů od res. manageru

Driver

- hlavní proces
- plánuje workflow
- distribuuje práci do exekutorů

Executor

- proces běžící na některém z nodů (ideálně na každém)
- provádí tasky (může i několik paralelně)



Důležité pojmy 2

Job


akce volaná uvnitř programu driveru

Stage

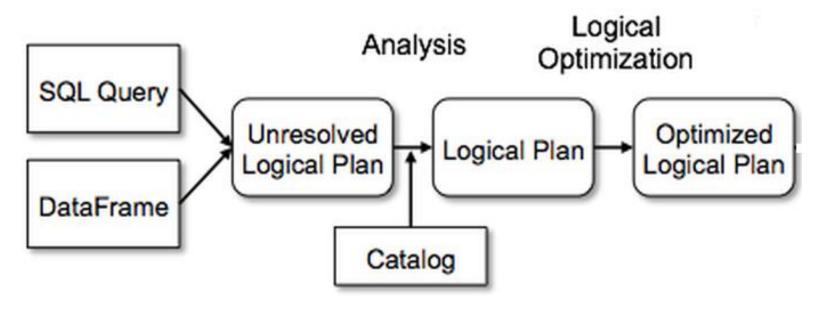
sada transformací, které mohou být vykonány bez shuffle

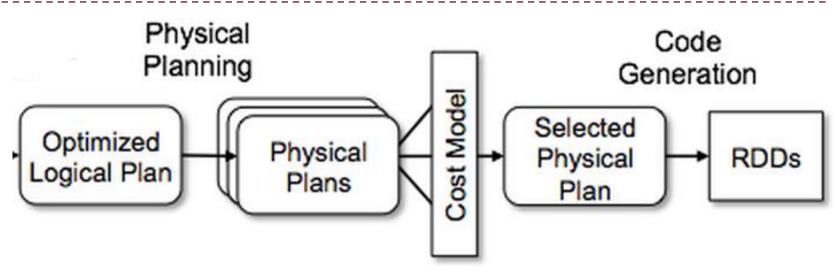
Task

jednotka práce, kterou provádí exekutor na nějakém kousku dat




Plánování a optimalizace






Plánování a optimalizace




- přetypování
- posloupnost transformací (např. přehození FILTER a JOIN)
- > volba typu JOINu, využití clusterování, partitions, skew apod.
- atd.

Plánování a optimalizace



- rozdělení a distribuce dat
- překlad transformací a akcí do příkazů pro JVM
- > atd.

Ukázka



- DAG graf popisující průběh výpočtu
- určení závislostí (X musí být uděláno před Y)
- optimalizace v rámci dodržení závislostí

Rozdělení dat – partitions

- partition část dat zpracovaná v jednom tasku
- defaultně 1 partition = 1 HDFS block = 1 task = 1 core
- partition se zpracuje na nodu, kde je uložená
- více partitions ⇒ víc tasků ⇒ vyšší paralelizace ⇒ menší velikost jedné partition ⇒ nižší efektivita ⇒ vyšší overhead
- ... a naopak

Lze ovlivnit? A jak?

- při VStupu: např. sc.textFile(soubor, počet_part)
- > Za běhu: coalesce, repartition, partitionBy
- shuffle!

Spuštění a konfigurace


Spuštění Sparku

pyspark | spark-shell | spark-submit --param value


Kde a jak poběží

- na clusteru plné využití paralelismu
 - mod client
 - mod cluster
- lokálně paralelní běh na více jádrech
- určeno parametry --master a --deploy-mode

Spark on YARN client mode



Spark on YARN cluster mode



Mod client versus mod cluster

- default je client
- mod client je vhodný pro interaktivní práci a debugging (výstup jde na lokální konzolu)
- mod cluster je vhodný pro produkční účely

Konfigurace běhu Sparku – požadavky na zdroje

- --name jméno aplikace
- --driver-memory paměť pro driver
- --num-executors počet exekutorů
- > --executor-cores počet jader pro exekutor
- > --executor-memory paměť pro exekutor

Příklad

- > pyspark --master yarn --deploy-mode client
 --driver-memory 1G
 --num-executors 3 --executor-cores 2
 - --executor-memory 3G

Příklad plánu alokace zdrojů

Obecná doporučení:

- --num-cores <= 5</p>
- --executor-memory <= 64 GB</p>

Cluster 6 nodů, každý 16 jader a 64 GB RAM

- Rezervovat 1 jádro a 1GB /node pro OS zbývá 6 *15 jader a 63 GB
- \rightarrow 1 jádro pro Spark Driver: 6 * 15 1 = 89 jader.
- > 89 / 5 ~ 17 exekutorů. Každý node (kromě toho s driverem) bude mít 3 exekutory.
- > 63 GB / 3 ~ 21 GB paměti na exekutor. Navíc se musí počítat s memory overhead -> nastavit 19 GB na exekutor

Díky za pozornost

PROFINIT

Profinit, s.r.o. Tychonova 2, 160 00 Praha 6







